Proyecto 2:

Gestión de Metadatos y Ciclo de Vida del Dato

1. Creación de Repositorios de Metadatos

Para resolver la falta de conocimiento homogéneo en EnergiTech, se ha implementado una estrategia de documentación basada en la norma **UNE 0087**.

En la siguiente tabla se muestra la propuesta de **Metadatos de Negocio (Glosario)**:

Versión	Término	Definición de Negocio	Responsable (Owner)	Estado
v1.0	Cliente Residencial	Persona física que consume energía para uso doméstico en viviendas particulares.	Dpto. Comercial	Aprobado
v1.0	Consumo Mensual	Suma total de energía (kWh) medida en un punto de suministro durante un ciclo de facturación.	Dpto. Facturación	Aprobado
v1.0	Cliente Crítico	Entidad (hospital, industria básica, seguridad) cuya interrupción de suministro supone un riesgo mayor.	Dpto. Operaciones	Aprobado
v1.0	CUPS (Código Universal)	Identificador alfanumérico único de 20 o 22 caracteres que identifica un punto de suministro de energía.	Dpto. Técnico / TI	Aprobado
v1.0	Demanda Prevista	Valor estimado de consumo energético para un periodo futuro, calculado mediante el modelo de IA.	Analista de Datos	Propuesto
v1.0	Umbral de Sobrecarga	Límite máximo de capacidad de un nodo de red antes de comprometer la estabilidad del suministro.	Dpto. de Red	Aprobado
v1.0	Nodo de Distribución	Punto físico de la infraestructura donde se ramifica la energía hacia los consumidores finales.	Ingeniería de Red	Aprobado
v1.0	Lectura Horaria	Registro del consumo de energía realizado por un contador inteligente en un intervalo de 60 minutos.	Dpto. de Sistemas	Aprobado
v1.0	Potencia Contratada	Capacidad máxima de energía (kW) que el cliente puede demandar simultáneamente según su contrato.	Dpto. Comercial	Aprobado
v1.1	Dato Maestro	Información clave y transversal (clientes, activos, hospitales) que debe ser gobernada para asegurar su veracidad en toda la organización.	CDO (Chief Data Officer)	Aprobado

v1.1	Golden Record	Perfil único y veraz de un cliente, creado tras unificar sus diferentes cuentas (luz, gas, etc.) en un solo ID Maestro.	Responsable de Calidad	Aprobado
v1.1	Matching	Proceso de comparación de registros basado en reglas (como el NIF/DNI) para identificar duplicidades y consolidar la información.	Arquitecto de Datos	En Revisión
v1.1	Fuente de Origen	Sistema primario (ERP, IoT, Clima) donde nace el dato antes de ser procesado por el núcleo de datos maestros.	Administrador de Sistemas	Aprobado
v1.1	Nivel de Confianza	Porcentaje de fiabilidad asignado a la unión de dos registros. Permite saber qué tan segura es la unificación antes de enviarla a la IA.	Analista de Datos	Aprobado

Los **Metadatos Técnicos (Catálogo)** describen el origen y la ubicación física. Para EnergiTech, vamos a definir los siguientes:

Versión	Tabla	Servicio	Esquema	Descripción
v1.0	FACT_CONSUMO	PostgreSQL_IoT	telemetria	Contiene las lecturas horarias brutas de los CUPS.
v1.0	DIM_CLIENTES	MySQL_ERP	ventas	Atributos de clientes, incluyendo el flag de "crítico".
v1.0	DIM_INFRAESTRUCTURA	MySQL_ERP	red	Relación de CUPS con Nodos de Distribución y transformadores.
v1.0	STG_METEO_FORECAST	API_Meteo_External	landing	Datos de temperatura y humedad previstos para las próximas 24h.
v1.0	OUTPUT_PREDICCION	PostgreSQL_IoT	analitica	Resultados del modelo de IA con la demanda estimada.
v1.1	MAESTRO_CLIENTE	MDM_Hub	maestro	Sustituye a **DIM_CLIENTES**. Es el Registro de Oro unificado con datos protegidos (PII).
v1.1	FUENTE_ORIGEN	MDM_Hub	maestro	**Nueva tabla**. Almacena la trazabilidad y el nivel de confianza del matching.

En cuanto a los **Metadatos Operativos (Diccionario)**, tenemos:

Para la tabla **FACT_CONSUMO** (v1.0)

Nombre de Columna	**Tipo de Dato**	**Restricciones (Constraints)**	**Descripción Operativa**
id_registro	BIGINT	Primary Key, Auto-increment	Identificador único interno para cada lectura recibida en el sistema.
cups_id	VARCHAR(22)	Foreign Key, NOT NULL	Código Universal de Punto de Suministro. Vincula la lectura con la tabla DIM_CLIENTES.
ts_lectura	TIMESTAMP	NOT NULL, Default: UTC	Marca de tiempo exacta del final del intervalo de lectura (formato ISO 8601).
val_kwh	DECIMAL(10,3)	NOT NULL, Check (val >= 0)	Valor de energía activa consumida en kilovatios-hora. Precisión de 3 decimales para evitar errores de redondeo.
id_calidad	INT	Default: 1	Flag de calidad: 1 (Real), 2 (Estimado), 3 (Erróneo).
version_modelo	VARCHAR(10)	Nullable	Versión del firmware del contador que realizó la lectura. Útil para auditoría técnica.

Para la tabla **DIM_CLIENTES** (v1.0)

Nombre de Columna	**Tipo de Dato**	**Restricciones (Constraints)**	**Descripción Operativa**
id_interno	INT	Primary Key	Clave subrogada interna del sistema ERP.
cups_id	VARCHAR(22)	Unique, NOT NULL	Código Universal de Punto de Suministro. Es el identificador único que evita duplicados.
nombre_titular	VARCHAR(100)	NOT NULL	Nombre y apellidos del titular. Sujeto a normativas de protección de datos (RGPD).
tipo_cliente	ENUM	'Residencial', 'Industrial', 'Pyme'	Categoría de cliente. Vinculado al término de negocio "Cliente Residencial".
ind_critico	BOOLEAN	Default: FALSE	Indicador de prioridad. TRUE identifica a hospitales o servicios esenciales.
id_nodo	VARCHAR(10)	Foreign Key	Identificador del nodo de red al que está conectado el cliente.

Para la tabla **STG_METEO_FORECAST** (v1.0)

Nombre de Columna	**Tipo de Dato**	**Restricciones (Constraints)**	**Descripción Operativa**
id_prevision	INT	Primary Key	Identificador único de la descarga de la API.
cod_estacion	VARCHAR(10)	NOT NULL	Código oficial de la estación meteorológica más cercana al nodo de red.
ts_prevision	TIMESTAMP	NOT NULL	Fecha y hora para la que se hace la predicción (ventana de 24h).
temp_celsius	DECIMAL(4,1)	Check (-50 a 60)	Temperatura prevista en grados Celsius. Factor crítico de correlación con el consumo.
prob_precip	DECIMAL(5,2)	Check (0 a 100)	Probabilidad de precipitación en porcentaje.
ts_captura	TIMESTAMP	Default: Now()	Momento exacto en el que se descargó el dato.

Para la tabla **DIM_INFRAESTRUCTURA** (v1.0)

Nombre de Columna	**Tipo de Dato**	**Restricciones (Constraints)**	**Descripción Operativa**
id_nodo	VARCHAR(10)	Primary Key	ID único del nodo (subestación o transformador).
nombre_nodo	VARCHAR(50)	NOT NULL	Nombre descriptivo de la ubicación física.
capacidad_max_kw	INT	Check (val > 0)	Potencia máxima soportada antes de riesgo de avería.
id_zona	INT	Foreign Key	Zona geográfica para agrupación administrativa.
latitud	DECIMAL(9,6)	NOT NULL	Coordenada geográfica (Latitud).
longitud	DECIMAL(9,6)	NOT NULL	Coordenada geográfica (Longitud).

Para la tabla **OUTPUT_PREDICCION** (v1.0)

Nombre de Columna	**Tipo de Dato**	**Restricciones (Constraints)**	**Descripción Operativa**
id_prediccion	BIGINT	Primary Key	ID único de la ejecución de la predicción.
id_nodo	VARCHAR(10)	Foreign Key	Referencia al nodo de red evaluado.
ts_objetivo	TIMESTAMP	NOT NULL	Fecha y hora para la que se predice el consumo.
val_predicho_kwh	DECIMAL(12,3)	NOT NULL	Carga total estimada (kWh) para ese intervalo.
prob_sobrecarga	DECIMAL(5,2)	Check (0 to 100)	Porcentaje de riesgo de superar la capacidad del nodo.
id_modelo_ia	VARCHAR(20)	NOT NULL	Versión del algoritmo (trazabilidad del modelo).
ts_ejecucion	TIMESTAMP	Default: NOW()	Momento en el que se generó este registro.

Herramientas software que podemos usar para cada tipo de metadato serían las siguientes:

Para los **Metadatos de Negocio (Glosario)** podríamos usar **OpenMetadata** o **Collibra**. Son ideales porque permiten que usuarios no técnicos busquen términos en lenguaje natural y vean quién es el responsable y la clasificación de seguridad.

Para los **Metadatos Técnicos (Catálogo)** existen herramientas como **OpenMetadata** o **AWS Glue Data Catalog**. Sobresalen en la conexión automática con bases de datos (escaneo de esquemas) y la visualización del **linaje del dato** (de dónde viene y a dónde va).

Para los **Metadatos Operativos (Diccionario)** podemos usar **DataHub** o el de nuevo el **Diccionario de Datos de OpenMetadata**. Permiten detallar el "tipo de dato", restricciones de integridad y estadísticas de ejecución (cuándo se actualizó la tabla por última vez).

Vamos a establecer la trazabilidad de algunos de los conceptos más importantes.

- **Cliente Residencial**: Esta trazabilidad permite que, cuando un Analista de Negocio consulta la definición en el glosario (Metadato de Negocio), el sistema le muestre automáticamente que dicha información se extrae de la tabla `DIM_CLIENTES` del esquema `ventas` (Metadato Técnico) y que, a nivel de implementación, debe filtrar la columna `tipo_cliente` por el valor específico 'Residencial' (Metadato Operativo). Esta conexión elimina errores de interpretación entre el equipo comercial y el equipo de análisis de datos.

Metadato de Negocio (Glosario)	Metadato Técnico (Catálogo)	Metadato Operativo (Diccionario)
Cliente Residencial.	**Servicio:** `MySQL_ERP`. **Base de Datos:** `ERP_EnergiTech`. **Esquema:** `ventas`. **Tabla:** `DIM_CLIENTES`.	**Campo:** `tipo_cliente`. **Regla de Negocio:** El valor de este campo debe ser estrictamente `'Residencial'` para que el registro sea considerado dentro de esta categoría en los informes de demanda. **Vinculación:** Se relaciona mediante la clave `cups_id` con la tabla de consumos para calcular la previsión específica de este segmento.

- **Consumo Mensual:** ejemplifica la trazabilidad de un dato derivado. Mientras que para el negocio representa la base de la factura (Metadato de Negocio), técnicamente se localiza en el repositorio de telemetría `FACT_CONSUMO` (Metadato Técnico). La trazabilidad operativa es aquí fundamental, ya que especifica que este valor no reside en una sola columna, sino que es el resultado de una agregación (SUM) de la columna `val_kwh` (Metadato Operativo). Esta definición única evita que el departamento de Facturación y el de Operaciones utilicen criterios de suma distintos, garantizando la homogeneidad de los informes.

Metadato de Negocio (Glosario)	Metadato Técnico (Catálogo)	Metadato Operativo (Diccionario)
Consumo Mensual.	**Servicio:** `PostgreSQL_IoT`. **Base de Datos:** `Analytics_Hub`. **Esquema:** `telemetria`. **Tabla:** `FACT_CONSUMO`. .	**Campo:** `val_kwh`. **Regla de Implementación (Cálculo):** Se obtiene mediante la suma (`SUM`) de la columna `val_kwh` filtrando por un `cups_id` específico y un rango de `ts_lectura` que comprenda el mes natural o el periodo de facturación. **Control de Calidad Asociado:** Se debe verificar el campo `id_calidad`. Para que el Consumo Mensual sea "Real", todos los registros sumados deben tener `id_calidad = 1`.

- **Cliente Crítico:** se vincula la definición estratégica del Departamento de Operaciones (Metadato de Negocio) con la columna física `ind_critico` de la base de datos ERP (Metadato Operativo). Esta conexión asegura que, cuando el modelo de IA procesa la tabla

DIM_CLIENTES (Metadato Técnico), reconozca automáticamente qué registros tienen prioridad absoluta. De este modo, si se detecta una posible sobrecarga en un nodo, el sistema utiliza esta trazabilidad para identificar instantáneamente si hay hospitales afectados, permitiendo una respuesta inmediata y precisa.

Metadato de Negocio (Glosario)	Metadato Técnico (Catálogo)	Metadato Operativo (Diccionario)
Cliente Crítico	**Servicio:** MySQL_ERP. **Base de Datos:** ERP_EnergiTech. **Esquema:** ventas. **Tabla:** DIM_CLIENTES.	**Campo:** ind_critico. **Regla de Implementación:** El valor TRUE (o 1) identifica al cliente como crítico. **Lógica de Negocio:** Este campo debe estar siempre completo (NOT NULL). Si un registro no tiene este flag definido, el sistema debe aplicar el principio de precaución y tratarlo como potencial crítico hasta su validación manual.

- **CUPS**: El representa el metadato de interconexión. La trazabilidad establecida permite asegurar la **Unicidad de Identificadores** mientras que el Glosario de Negocio lo define como el identificador invariable del punto de suministro, la trazabilidad operativa impone una restricción de UNIQUE en la columna cups_id. Al estar documentado, cualquier proceso técnico sabe que debe validar el formato de esta columna antes de permitir su almacenamiento, garantizando que los datos de consumo se asignen siempre al cliente correcto sin riesgo de duplicidades.

Metadato de Negocio (Glosario)	Metadato Técnico (Catálogo)	Metadato Operativo (Diccionario)
CUPS	**Origen (Maestro):** Servicio MySQL_ERP, Tabla DIM_CLIENTES. Aquí se asocia el CUPS a una persona/entidad. **Uso (Transaccional):** Servicio PostgreSQL_IoT, Tabla FACT_CONSUMO. Aquí el CUPS identifica de quién es cada lectura recibida.	**Campo:** cups_id. **Regla de Integridad:** Debe ser UNIQUE y NOT NULL. **Validación de Formato:** Debe cumplir el estándar ISO (en España empieza por "ES" seguido de 16 o 20 dígitos y letras de control). **Vinculación:** Actúa como **Clave Primaria** en DIM_CLIENTES y como **Clave Foránea** en FACT_CONSUMO.

2. Gestión del ciclo de vida

Para asegurar la integridad y utilidad de la información en EnergiTech, se define el siguiente ciclo de vida, alineado con el proceso de negocio y los controles técnicos establecidos. En la fase de transformación se indican las validaciones que deben aplicarse. Además, para cada etapa se establece una propuesta de políticas específicas que permitan regular qué se puede hacer y qué no se puede hacer con los datos:

1. Etapa de Ingesta (Capture)

- **Proceso:** Recolección mediante arquitectura de eventos de lecturas de Smart Meters (PostgreSQL), datos maestros (MySQL) y previsiones climáticas (API).
- **Linaje Técnico:** Generación automática de `ts_captura` y metadatos de origen para asegurar la trazabilidad del dato bruto.
- **Políticas de gobierno:**
    - **Política de Origen Autorizado:** Solo se permite la ingesta de datos provenientes de fuentes técnicas registradas en el catálogo (Smart Meters, ERP y API Meteo). Cualquier nueva fuente debe ser dada de alta en los metadatos técnicos antes de iniciar la captura.
    - **Política de Integridad en el Punto de Entrada:** Queda prohibida la ingesta de registros de consumo que no incluyan el metadato operativo `ts_captura` o que carezcan de un `cups_id` válido.
    - **Prohibición de Entrada Manual:** No se permite la inserción manual de lecturas de consumo en la tabla `FACT_CONSUMO` para evitar la manipulación de la serie temporal.

2. Etapa de Transformación (Processing)

- **Proceso:** Fase de refinamiento donde el dato bruto se normaliza y prepara para el motor predictivo:
    - **Conversión:** Estandarización de unidades a **kWh** con precisión de tres decimales (`DECIMAL(10,3)`).
    - **Tratamiento de nulos:** Aplicación de **media móvil de los últimos 3 registros** para completar huecos de lectura, garantizando la continuidad de la serie.
    - **Enriquecimiento:** Cruce de cada `cups_id` con su `id_nodo` y el flag `ind_critico` para segmentar la prioridad.
- **Controles de validación:**
    - **Validación Sintáctica:** Verificación de estructura alfanumérica del **CUPS** y conversión de marcas de tiempo a formato **UTC**.
    - **Validación Semántica:** El consumo (`val_kwh`) debe ser >= 0 y la temperatura debe oscilar entre **-50ºC y 60ºC**.
    - **Validación de Integridad:** Comprobación de existencia del CUPS en la tabla maestra `DIM_CLIENTES` antes de procesar su consumo.
    - **Validación de Completitud:** Si en 24h falta más del **2% de las lecturas**, se dispara una alerta de "Calidad de Datos Insuficiente" para evitar predicciones sesgadas.
- **Políticas de gobierno:**

- **Política de Protección de privacidad:** Durante el procesamiento de datos de la tabla `DIM_CLIENTES`, cualquier dato etiquetado como **"PII Sensitive"** (como el nombre del titular o su condición de salud/crítico) debe ser enmascarado o cifrado si se traslada a entornos de desarrollo o pruebas.
- **Política de Calidad Mínima:** Si un dataset unificado presenta una tasa de nulos superior al **2%** tras aplicar la media móvil, el proceso de transformación debe detenerse y notificar al **Data Steward**.
- **Inalterabilidad del Histórico:** No se permite la modificación de los datos brutos originales durante la transformación; cualquier corrección debe generar una nueva versión del dato en la capa analítica.

3. Etapa de Almacenamiento (Storage)

- **Proceso:** Persistencia segura y optimizada de los activos de datos utilizando las tablas técnicas definidas (`FACT_CONSUMO`, `DIM_CLIENTES`, `DIM_INFRAESTRUCTURA` y `STG_METEO_FORECAST`).
- **Políticas específicas:**
  - **Política de Control de Acceso (RBAC):** El acceso a la base de datos `ERP_EnergiTech` (esquema `ventas`) está limitado exclusivamente a personal con perfil de gestión comercial, debido a la presencia de **"Personal Data"**.
  - **Política de Retención:** Los datos de la tabla `STG_METEO_FORECAST` se consideran volátiles y deben ser archivados o eliminados tras **30 días** para optimizar el almacenamiento, ya que pierden relevancia operativa para la IA.
  - **Cifrado en Reposo:** Todos los datos almacenados en el servicio `PostgreSQL_IoT` que contengan relaciones entre CUPS y consumo deben estar cifrados.

4. Etapa de Explotación (Usage/Analysis)

- **Proceso:** El modelo de IA procesa el dataset unificado para generar la tabla `OUTPUT_PREDICCION` con la demanda estimada.
- **Validación de Negocio:** si la demanda prevista en un nodo supera el **90% de su capacidad contratada/máxima** (`capacidad_max_kw`), se marca el registro como **"Incoherente"** para revisión manual inmediata por parte del Analista de Demanda.
- **Consumo Final:** Distribución de informes y visualización en cuadro de mando para la toma de decisiones preventivas en la red eléctrica.
- **Políticas específicas:**
  - **Política de Validación Humana:** Queda prohibida la ejecución de cortes de suministro automáticos basados en la tabla `OUTPUT_PREDICCION` si el registro ha sido marcado como **"Incoherente"** (demanda > 90% capacidad); estos casos requieren la validación obligatoria del Analista de Demanda.
  - **Política de Propósito Limitado:** Los datos de **"Cliente Crítico"** solo pueden utilizarse para fines de priorización de suministro y prevención de sobrecargas, prohibiéndose su uso para campañas comerciales o marketing.
  - **Prohibición de Exportación Masiva:** No se permite la descarga de tablas completas de la capa de explotación hacia dispositivos locales (Excel/CSV) sin una solicitud justificada y aprobada por el **Owner** del dato (Dpto. de Operaciones o Comercial).