Proyecto 3:

Gestión de Datos Maestros y Arquitectura y Diseño de Datos

1. Creación de Datos Maestros

1.1. Modelo de registro de datos maestros: entidad `MAESTRO_CLIENTE`

A diferencia de la tabla `DIM_CLIENTES` definida en el Proyecto 2, que está vinculada directamente al punto de suministro (`cups_id`), el modelo maestro se abstrae del contrato para centrarse en la **identidad del sujeto**.

Los atributos maestros propuestos de la nueva entidad son:

Atributo	Descripción	Tipo de Dato
`id_maestro_cliente`	Clave primaria única generada por el sistema.	`UUID / BIGINT`
`nif_dni_nie`	Documento de identidad (Atributo clave de unicidad).	`VARCHAR(15)`
`nombre_titular`	Nombre y apellidos normalizados.	`VARCHAR(100)`
`fecha_nacimiento`		
`dirección_maestro`		
`email_maestro`	Correo electrónico verificado y preferente.	`VARCHAR(100)`
`telefono_maestro`	Teléfono móvil de contacto principal.	`VARCHAR(15)`
`ind_critico_maestro`	Flag que consolida si es cliente crítico en cualquier servicio.	`BOOLEAN`
`fecha_alta_original`	Fecha de la primera contratación en EnergiTech.	`DATE`

1.2. Atributos de matching (identificación y unificación)

Para realizar el proceso de **Matching** y detectar que IDs pertenecen a la misma persona física, se propone una lógica de dos niveles:

- **Matching Determinístico (Hard Match):** Uso del campo `nif_dni_nie`. Es el identificador legal único en España. Si dos registros de distintos sistemas (luz y gas) comparten este número, se fusionan automáticamente bajo el mismo `id_maestro_cliente`.
- **Matching Probabilístico (Fuzzy Match):** En caso de ausencia de DNI en algún silo, se utilizarán:
    - **Nombre y apellidos:** Aplicando reglas de limpieza para ignorar tildes o variaciones de escritura.
    - **Dirección de suministro:** Si el nombre coincide y la dirección es idéntica, la probabilidad de ser el mismo cliente es alta.

- **Fecha de nacimiento, teléfono e email:** Como factores de refuerzo para confirmar la identidad.

1.3. Fuente de verdad

Se establece que el **ERP Corporativo (`MySQL_ERP`)** sea la **Fuente de Verdad** para los datos maestros de clientes. El sistema ERP es donde se gestiona la contratación legal y la facturación, procesos que exigen la máxima veracidad y cumplimiento normativo (RGPD) sobre los datos de identidad.

1.4. Datos de referencia

Para garantizar la homogeneidad y reducir la ambigüedad, el modelo maestro se apoyará en los siguientes datos de referencia:

- **Tipo de cliente:** Segmentación estandarizada: `'Residencial'`, `'Industrial'`, `'Pyme'`.
- **Estado de suministro:** `Activo`, `Inactivo`, `Baja`, `Pendiente de Pago`.
- **Codificación geográfica:** Uso de tablas maestras de provincias y municipios oficiales (INE) para normalizar las direcciones.
- **Categoría de prioridad:** Vinculado al glosario de "Cliente Crítico" para servicios de emergencia.

En la siguiente imagen se muestra el modelado realizado en Visual Paradigm

- **La entidad `MAESTRO_CLIENTE`**

  Esta tabla representa el **Registro de Oro** (*Golden Record*), es decir, la versión única y limpia de la información del cliente.

  - **`ID_maestro_cliente`**: Es el **Identificador Único Maestro**
  - **`nif_dni_nie`**: Aparece con una "U" roja, lo que indica que es **único**.
  - **`ind_critico_maestro`**: permite identificar a hospitales o servicios esenciales de forma global.
  - **Atributos de apoyo**: `direccion_maestro` y `fecha_nacimiento` son ideales para el **Matching** por similitud que comentamos anteriormente.

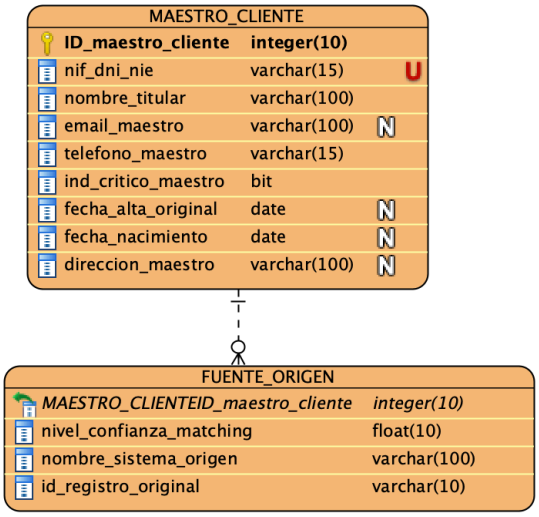

- **La Entidad `FUENTE_ORIGEN`**

  Permite que el **Repositorio de Datos Maestros** sepa de dónde viene cada dato:

  - **`nombre_sistema_origen`**: Aquí es donde registraríamos si el dato viene del **Sistema de Gestión Empresarial** (`MySQL_ERP`, nuestra **Fuente de Verdad**) o de otros sistemas.

- `id_registro_original`: Aquí guardaríamos los tres IDs distintos que tenía "Juan Pérez" en los sistemas antiguos. Así, el modelo maestro "recuerda" sus identidades anteriores pero las agrupa en una sola.
- `nivel_confianza_matching`: Este campo es clave para la **Comparación por Similitud**. Permite guardar qué tan seguros estamos (por ejemplo, un 95%) de que el registro del sistema de gas es realmente el mismo "Juan Pérez" del sistema de luz.

2. Arquitectura y diseño de datos

Proponemos una arquitectura **Centralizada**. Este diseño permite que todos los sistemas de EnergiTech consulten una única versión de la verdad.

Para que el intercambio de datos sea fluido, dividimos la arquitectura en tres niveles:

1. Zona de Sistemas de Origen (La entrada de información)

Es donde se genera la información inicialmente en sus propios "silos" o almacenes separados:

- **Gestión Comercial (`MySQL_ERP`)**: Contiene los datos maestros de clientes y contratos.
- **Red y Telemetría (`PostgreSQL_IoT`)**: Recoge las lecturas de los contadores inteligentes cada hora.
- **Datos Externos (`API_Meteo`)**: Provee las previsiones del tiempo (temperatura y humedad).

2. Zona de Datos Maestros (El núcleo de unificación)

Es el corazón del sistema, donde aplicamos el modelo que diseñamos en la Tarea 1.

- **Proceso de *Matching*** (Comparación): El sistema recibe los datos de clientes de distintas fuentes y usa el NIF/DNI para confirmar que son la misma persona.
- **Creación del Registro de Oro** (*Golden Record*): Se genera una ficha única para el cliente, eliminando la duplicidad de IDs.
- **Control de Confianza**: Se anota qué tan fiable es la unión de los datos mediante el campo `nivel_confianza_matching`.

3. Zona Analítica (La salida para la Inteligencia Artificial)

Es el repositorio final donde los datos ya están limpios y listos para ser usados. En esta zona se encuentran los datos enriquecidos, donde se junta el consumo de energía con la ficha única del cliente y la previsión del tiempo.

El modelo de Inteligencia Artificial lee directamente de aquí para hacer la **demanda prevista** sin errores causados por duplicados

Para que los sistemas hablen entre sí sin crear duplicados, el intercambio sigue estos pasos:

1. **Extracción y Carga**: Los datos de "Juan Pérez" viajan desde el sistema de luz, gas y mantenimiento hacia el Núcleo Central.
2. **Unificación y Limpieza**: El Núcleo Central detecta que esos tres registros son la misma persona usando el Documento de Identidad (NIF/DNI).
3. **Sincronización de Identidad**: Una vez unificado, el Núcleo envía de vuelta el **ID Maestro** a los sistemas de origen. Así, el sistema de los contadores inteligentes etiqueta las lecturas con el nuevo ID unificado.
4. **Preparación para la IA**: Se crea una tabla unificada que combina el consumo real, la temperatura prevista y la información de si el cliente es **Crítico** (como un hospital).

Esta arquitectura está orientada al análisis porque:

- **Elimina la Ambigüedad**: La Inteligencia Artificial ya no ve tres consumos pequeños para tres IDs distintos, sino un consumo total real para un único cliente maestro.
- **Garantiza la Confianza**: Al usar el **Nivel de Confianza** que definimos en el modelo, el analista sabe qué tan fiables son los datos unificados antes de tomar decisiones sobre la red eléctrica.
- **Automatiza la Calidad**: El flujo incluye las reglas de limpieza que definimos en el Proyecto 2, asegurando que el dato que llega al final del ciclo está listo para ser usado.